

第三阶段综合应用 与终局验收

以 CareAI 为测试案例验证 VentureAI V2

验收标准 · 竞品比较 · 修改前后证据 · 最终结论

证据链

G1—G6

立项闯关



F1 / F2 / F3

三流程



100 + 100

双门槛



D1—D9

版本推进



F / I / H / S

证据边界

先给结论：从“会回答”升级为“可验收”

第三阶段关注可信过程，而不是生成材料的长度

01 功能闭环

立项 → 材料 → Agent 使用 → 独立评分 → 排名 / 答辩 → 终局结论

02 CareAI 流程证据

ready = true ; 缺项 = 0 ; F1/F2/F3 全覆盖 ; 7 条材料版本 ; 4 条 Agent 运行

03 证据边界

项目分 68 、 Agent 分 71 、教师判断与 D1—D9 均标为 S （模拟），不冒充真实课程成绩

最终判定

VentureAI 第三阶段功能与证据机制：完成

CareAI 真实课程终局验收：仍须学生真实材料 + 任课教师复审 + 现场答辩

终局验收不是一个分数，而是一条不可跳过的链

任何关键节点失败，都不能由其他高分补偿



关键规则：立项更新、计划书更新后，旧评分和旧终局结论自动失效，必须按当前版本重新验收。

G1—G6：先证明项目值得做，再进入正式材料

教师逐项判断；学生更新立项书后，旧版通过自动失效

G1 问题具体

用户、场景、问题可识别

G2 证据成立

来源可查，结论不过度

G3 边界透明

F/I/H/S 标注完整

G4 方案匹配

回应问题并说明边界

G5 价值可行

社会价值、创新、实施路径

G6 Agent 可追溯

V2 参与且运行可定位

再审要求：上一版 → 教师反馈 → 具体修改 → 验证结果；只换措辞不算有效修改。

提交物必须成套、同源、同版本

系统同时检查“有没有”和“是否绑定当前版本”

01 立项书

通过版 + 历次反馈

02 商业计划书

12 章；关键数字可回溯

03 路演 PPT

建议 12—16 页；与计划书一致

04 10 分钟讲稿

保存实际计时，≤ 600 秒

05 5 分钟问答库

≥10 个高风险问题

06 阶段总结

成果、Agent 贡献、局限

Agent 生成只能保存为草稿；必须由学生核验、修改并以 student 版本提交，才算正式材料。

F1 / F2 / F3 : 证明 Agent 确实参与并产生作用

每条记录同时保存任务、输入版本、处理理由、结果版本、证据位置与效果判断

F1 理论学习

- Tutor 运行
- 理解检查
- 错误与纠正

F2 项目指导

- Coach/ 竞品 / 答辩运行
- 采纳 · 拒绝 · 重写 · 补充
- 映射成果版本

F3 评审反馈

- Grader 初评
- 定位问题并修改
- 另一 run 复验

可追溯字段: run_id · session · project · Agent 版本 · Git 提交 · 模型 · 代码 / 提示词哈希 · 状态 · 时间

评分与排序：门槛负责通过，排名负责区分

高总分不能补偿任一门槛低于 60 分

68

项目成果 / 100
S（模拟）

71

Agent 效果 / 100
S（模拟）

—

现场答辩 / 100
教师现场录入

D8 暂列

$(\text{项目分} + \text{Agent 分}) \div 2$
仅双门槛通过者进入；约前 50%

D9 入围组最终排序

$\text{项目分} + \text{Agent 分} + \text{答辩分} = 300$
分总成绩

仍由教师确认同分、材料和红线

CareAI 与蚂蚁阿福：先公平比较，再谈选择

阿福已有健康档案与健康小目标；不能靠贬低竞品建立差异化

比较维度	CareAI 当前证据	蚂蚁阿福公开信息
产品阶段	可演示 MVP ； 无真实用户 / 留存 / 付费证据	已公开运营的健康 AI 应用
档案与目标	基础记录、规则提示、7 天行动计划	个人 / 家庭健康档案、健康小目标与提醒
服务范围	非诊断健康教育与习惯管理	健康咨询、报告解读、档案及挂号 / 云陪诊等服务
可检验差异	规则可追溯、AI 受限、边界可见	生态与服务能力强；具体体验须同条件实测
证据结论	技术功能 F ； 用户偏好与竞争优势 H	功能来自官方公开资料；不推断其实际效果

来源1: [蚂蚁阿福 App Store 产品页](#)

来源2: [人民日报 \(数据来源: 蚂蚁集团\)](#)

核对日期 2026-09-15

为什么用户可能选择 CareAI？答案目前是四个待验证假设

差异化必须通过同条件任务证明，不能直接写成市场事实

H1

更容易理解

规则结果与 AI 解释分层；用户能说清“这不是诊断”

H2

更容易行动

固定输出“指标—原因—建议—7天计划”，减少下一步不明确

H3

更容易复核

规则版本、阈值、输入和输出可追溯；错误更容易定位

H4


更少数据负担

课堂场景只用虚构资料；真实发布仍须完成隐私与授权设计

当前可以说“值得测试”，不能说“用户已经更喜欢 CareAI”。

公平对照测试：同一任务、同一资料、交换顺序

不采集真实健康数据；参与人数与知情安排由课程教师决定



统一观察指标	任务完成	耗时	操作步骤	提示理解
	行动清晰度	边界理解	主观偏好	

输出：观察表 + 差异解释 + 局限 + 下一轮修改；不要只报平均分。

修改前 | 项目定位被错误改写

同一 CareAI 项目、同一任务；截图保留原始对话和评分界面



BEFORE · P0

画面说明

把非诊断健康教育项目说成心理健康筛查，并补造 NLP、访谈和用户。

为什么重要

一旦项目事实错，后续商业建议、验证任务和合规判断都会沿着错误前提扩散。

修改前 | 评分有数字，却没有可靠证据边界

同一 CareAI 项目、同一任务；截图保留原始对话和评分界面



BEFORE · P1

画面说明

R1—R11 有分数，但部分团队、商业和材料依据不在提交文件中。

为什么重要

分数无法回到材料位置，就不能证明评分正确，也不能指导学生具体修改。

修改后 | 先复述事实，再说缺口

同一 CareAI 项目、同一任务；截图保留原始对话和评分界面



AFTER · PASS

画面说明

准确识别非诊断定位、真实完成的 MVP、规则与 AI 分层，并把未验证项说清楚。

为什么重要

建议开始于学生真实材料；资料缺失时明确“未提供 / 待验证”，减少幻觉传播。

修改后 | 评分绑定依据、缺口与下一步

同一 CareAI 项目、同一任务；截图保留原始对话和评分界面



AFTER · PASS

画面说明

R1—R11 逐项显示评分、材料依据、缺失证据和可执行建议。

为什么重要

学生能定位问题，教师能复核判断，修改后还能用新 run_id 做复验闭环。

修改为什么有效：把提示词约束变成产品门槛

单靠“请勿编造”不够；数据库、权限、版本与界面共同阻断错误



学生端：材料版本、立项状态、证据导出



教师端：G1—G6、独立评分、D8/D9 排名

事实约束 + 项目权限 + run 追踪 + 材料哈希 + 版本失效 + 人工确认 = 可审计的验收系统

终局结论与下一步

系统已经就绪；真实成绩仍必须来自真实材料和真实教师

已完成

- G1—G6、版本材料、F1/F2/F3、F/I/H/S、D1—D9
- 项目 / Agent / 答辩三张 100 分表与 D8/D9 排名
- CareAI 修改前后截图、原始 JSON、权限状态码
- 15 项后端测试、TypeScript 与生产构建通过
- V2 标签：ventureai-v2-stage3-2026-09-15

真实验收还需

- 替换 S 模拟材料
- 教师本人复审评分
- 10 分钟路演 + 5 分钟答辩
- 完成合规的对照验证

第三阶段的核心不是“AI 写了多少”，而是“结果是否可信、可追溯、可答辩”。