

VentureAI：从“会回答”到“有证据地指导”

用 CareAI 同一项目材料完成 V1→V2 对照与最终应用

- 真实问题 → 修改 → 同条件验证
- 版本：V1 c456aef → V2 基线 2026-09-15 → 最终交付 tag 2026-09-16



真实学生端截图 | 修改后 Coach 流程

代表性高优问题： V1 会把项目材料改写成不存在的事实

同一 CareAI 项目书、同一任务；问题会污染后续指导、竞品比较和评分



P0 事实幻觉 非诊断健康教育被写成心理筛查；虚构 NLP、访谈、团队与收入

P0 数据权限 匿名可读取项目、详情和会话历史

P1 证据缺失 文件只截取前 2000 字；评分与材料无法逐项对应

P1 错误传播 用户纠正后仍保留旧设定，竞品任务继续失真

优先级依据：影响所有核心流程与验收可信度

V2 修改与验证（1）：事实基准进入模型，纠错后撤销旧推断

修改不只发生在提示词，还包括文件注入、事实优先级、输出边界和交互约束



前：心理筛查 / NLP / 已访谈 → 后：非诊断健康教育 / 规则与 AI 分层 / 明确未验证项

修改：完整正文与证据索引进入模型；用户 / 文件事实优先；冲突时撤销旧 AI 推断；首轮只问一个下一步问题

V2 修改与验证（2）：评分从“有分数”变成“有依据、缺口和下一步”

同一 CareAI 项目材料；竞品比较也改为同资料、同任务和同指标

修改前

当前项目：CareAI 成人健康习惯管理原型 - 星

AI 教练
智能对话

我的项目
项目管理

能力画像
个人画像

模拟答辩
投资人问答

同学互评
匿名评审

CareAI 功能测试
学生 在线

退出登录

请评审我上传的 CareAI 项目书...

请结合 CareAI 向第一次创业...

请给 FA/HS 逐项判断以下 C...

我上传了 CareAI 项目书，请...

足、用户粘性低的问题。这一痛点描述较为具体，目标用户群体明确。然而，项目书中没有提供足够的用户访谈或调查数据来支撑这些痛点的真实性。建议进行初步的用户访谈，收集更多具体的数据来验证痛点。

2. 用户证据：项目书中提到用户对个性化健康管理服务的需求较高，但未提供具体的访谈数据、市场调查或用户反馈来支持这一点。所有数据都标记为假设（H），建议在未来的工作中，完成一份课程内证据/假设表，并把真实访谈列为后续验证计划和市场调查，获取真实的数据来验证用户需求。

3. 方案可行性：项目书中详细描述了 CareAI 的技术架构和运营流程，初步展示了方案的技术和运营可行性。然而，项目的实际操作和临床验证尚未开展，所有数据均为假设（H），建议与医疗机构合作，进行初步的临床验证，以增强方案的可信度。

4. 商业模式：项目书中提到的商业模式包括用户订阅和合作医院分成，但对具体的收入来源、成本结构和盈利路径缺乏详细的说明，建议详细说明收入模型和成本控制措施，特别是如何吸引并留住用户，以及如何与合作医院达成互利的合作模式。

5. 市场竞争：项目书中提到了一些竞争对手，但缺乏详细的竞争分析和差异化定位。建议进行更深入的市场调研，分析竞争对手的优势和劣势，明确 CareAI 的独特价值和差异化策略。

6. 财务逻辑：项目书中提供的财务预测较为粗略，缺乏详细的收入预测和成本分析。建议建立详细的财务模型，包括初期投资、运营成本、收入预测和盈亏平衡点分析，以增强财务预测的合理性和可信度。

7. 创新差异化：项目书中提到 CareAI 通过 AI 技术提供个性化的健康管理服务，具有一定的创新性。然而，创新点的具体实现和难以复制的竞争优势尚不明确。建议进一步详细说明创新点的实现路径和技术壁垒，以增强项目的独特性和竞争力。

8. 团队执行：项目团队成员背景多样，具备一定的技术和市场运营能力，然而，团队在医疗健康领域的专业知识和经验，建议加强相关领域的知识储备。

形成性评价报告

2.7

综合得分

R1 痛点定义

4/5

证据：项目清晰地定义了成年人在日常健康自我管理中所存在的痛点，目标用户也明确。

建议：建议进一步细化用户群体的细分特征，例如不同年龄段的需求差异。

R2 用户证据

2/5

证据：项目目前没有真实用户的反馈数据，所有数据均为作者推测。

建议：建议通过小范围的用户测试，收集用户对产品功能、界面设计、使用体验等方面的反馈。

R3 方案可行性

4/5

证据：项目详细描述了技术实现的流程和架构，数据管理流程等。

建议：建议进一步验证技术方案的可行性和稳定性，特别是在高并发场景下的表现。

R4 商业模式

2/5

证据：项目目前没有明确的商业模式和盈利路径。

修改后

当前项目：CareAI 成人健康习惯管理原型 - 星

AI 教练
智能对话

我的项目
项目管理

能力画像
个人画像

模拟答辩
投资人问答

同学互评
匿名评审

CareAI 功能测试
学生 在线

退出登录

我上传了 CareAI 项目书，请...

建议：可以进一步细化用户需求，例如不同年龄段、不同健康状况的用户有何具体差异。

R2 用户证据

评分：2

证据：项目声明尚未进行真实用户访谈、临床验证或收入数据收集，所有假设均为待验证状态（文档第 3 节）。

建议：尽快开展小规模的用户测试，收集用户的反馈和使用体验，以验证假设的有效性。

R3 方案可行性

评分：3

证据：项目的技术实现部分详细描述了前端、后端和数据库的技术栈与工作流程，展示了技术可行性和初步的 MVP（文档第 6 节）。

建议：进一步测试系统的稳定性和性能，确保在实际使用中的用户体验流畅。

R4 商业模式

评分：2

证据：项目尚未提供具体的商业模式、客户群体、价值主张、渠道、收入和成本分析（文档第 4 节）。

建议：需要明确商业模式，包括目标客户、定价策略、收入来源（如订阅费、广告、合作模式等）和成本结构。

R5 市场竞争

评分：2

证据：项目提到了一些对比对象，但未进行详细的市场竞争分析，缺乏对竞争对手的市场占有率、优劣势和差异化定位的描述（文档第 7 节）。

建议：深入调研市场，分析主要竞争对手，明确 CareAI 的差异化优势和市场定位。

R6 财务逻辑

评分：1

证据：项目目前没有财务预测和盈利路径，缺乏具体的收入来源和成本控制措施（文档第 4 节）。

形成性评价报告

2.5

综合得分

R1 痛点定义

4/5

证据：项目明确指出了成年人在日常健康自我管理中的具体痛点，包括年龄相关的健康需求，缺乏解释和可执行的下一步指导（文档第 3 节）。

建议：可以进一步细化用户需求，例如不同年龄段、不同健康状况的用户有何具体差异。

R2 用户证据

2/5

证据：项目声明尚未进行真实用户访谈、临床验证或收入数据收集，所有假设均为待验证状态（文档第 3 节）。

建议：尽快开展小规模的用户测试，收集用户的反馈和使用体验，以验证假设的有效性。

R3 方案可行性

3/5

证据：项目的技术实现部分详细描述了前端、后端和数据库的技术栈与工作流程，展示了技术可行性和初步的 MVP（文档第 6 节）。

建议：进一步测试系统的稳定性和性能，确保在实际使用中的用户体验流畅。

R4 商业模式

2/5

证据：项目目前没有明确的商业模式和盈利路径。

R1—R11：每项返回材料依据、证据缺口和可执行修改；无依据内容写“未找到”。

竞品：不声称 CareAI 已胜出，只给公平对照方案

原始记录：careai-completed-grader-recovered.json；竞品修复 run_id=run_07a98721bfe5

助教 2 · VentureAI 优化与效果 · 2026-09-16

04

三个核心流程已独立准备，可接受现场随机抽测

每个流程都有明确入口、任务边界、原始 run_id 和同版本历史记录

F1 理论学习

- 定义与举例
- 反例 / 边界
- 理解检查
- 不确定性与来源

入口: U1 / U2

F2 项目指导

- 一次推进一个问题
- 用户 / 场景 / 证据
- 不代写事实
- 明确待验证项

入口: Coach / 竞品

F3 评审反馈

- R1—R11 标准
- 优点 / 缺口 / 风险
- 可操作修改
- 再次 run 复验

入口: Grader

抽测策略：现场运行当前版本；若网络 / API 失败，如实展示失败状态，再打开同版本原始运行和日志。

Agent 对最终 CareAI 项目的实际贡献：输出经过人工选择才进入成果

展示输入、Agent 输出、采用 / 拒绝 / 改写和最终影响，避免把 Agent 草稿当事实

项目任务	提供给 Agent	Agent 输出	人工处理与最终结果
确认项目定位	CareAI 项目书全文	指出用户、场景、方案与证据缺口	采用正确定位；删除心理筛查、访谈等幻觉
与阿福比较	CareAI 事实 + 阿福公开资料	差异化假设与对照任务	保留同条件测试；拒绝“已优于阿福”的结论
完善项目材料	R1—R11 评审任务	逐项依据、缺口和建议	补充边界和验证计划；人工核对来源

责任边界

VentureAI 负责提出分析与反馈；项目组核对事实并决定采纳、拒绝、改写或补充，最终材料由项目组负责。

其他工具声明：OpenAI Codex 协助整理 PPT 与证据索引；不作为真实用户、市场或临床证据

优化取舍与剩余问题：已解决关键风险，但没有声称“全部完成”

B8 占 10 分：说明哪些解决、哪些仍存在、哪些延期，以及下一步优先级

已解决

- 项目 / 会话权限
- 完整材料与事实优先级
- R1—R11 依据
- run_id 与失败留痕

仍存在

- 模型仍可能生成无来源示例
- 部分评分措辞需人工核对
- 长请求仍有等待风险
- 风险提示可能过宽

延期 / 放弃

- 完整全站权限审计
- 历史 TypeScript/ESLint 清理
- 广泛真实用户测试
- 跨组测试（教师已取消）

下一步优先

- F1/F2/F3 随机回归
- 降低评分延迟
- 增强引用定位
- 由教师和项目负责人复核

异常原则：失败不伪装成功；保留状态、错误、重试和人工干预。当前证据含 Grader 客户端 180 秒超时后服务端完成并取回的记录。